Итоги выполнения лабораторных работ по дисциплине «Рекомендательные системы»

В ходе выполнения пяти лабораторных работ были последовательно рассмотрены базовые, памятностные, факторизационные, гибридные и последовательные подходы к построению рекомендательных систем на датасете KION. Ниже приведены краткие итоги по каждой работе и сводные количественные результаты.

1. Результаты по лабораторным работам

Лабораторная работа 1. Базовые рекомендательные алгоритмы

Выполнен первичный анализ датасета и подготовлен набор данных для последующих экспериментов. Реализованы базовые методы random, popular и top popular. В рамках данной группы наилучший результат по MAP@10 показал метод popular (0,05919), что подтверждает устойчивость популярностного базлайна для сценариев с ограниченной персональной историей.

Лабораторная работа 2. Памятностные модели UserKNN и ItemKNN

Реализованы модели UserKNN и ItemKNN. По совокупности рассчитанных top-k метрик более сильный результат показал UserKNN (MAP@10 = 0,05061), тогда как ItemKNN заметно уступил. Это указывает на то, что для рассматриваемого набора данных поиск похожих пользователей оказался эффективнее, чем поиск похожих объектов.

Лабораторная работа 3. Матричная факторизация ALS

Реализована модель ALS с подбором гиперпараметров. Итоговое качество составило HitRate@10 = 0,13653 и MAP@10 = 0,05298. После настройки параметров ALS немного превзошла UserKNN по MAP@10 и приблизилась к популярностному базлайну, что показывает, что для данного набора данных факторизационная модель начинает работать конкурентоспособно при более аккуратной настройке.

Лабораторная работа 4. Гибридная модель LightFM

Построена модель LightFM на матрице взаимодействий user-item. По итогам эксперимента именно LightFM показала наилучшее качество среди моделей, оцененных в сопоставимом top-k протоколе: HitRate@10 = 0,17590 и MAP@10 = 0,07023. По сравнению с ориентировочными реализациями улучшение результата, вероятно, связано с более аккуратной подготовкой матрицы взаимодействий,

исключением уже просмотренных объектов из выдачи и стабильной средой запуска.

Лабораторная работа 5. Последовательная модель GRU4Rec

Реализована последовательная модель GRU4Rec в постановке next-item prediction. В отличие от предыдущих лабораторных работ, здесь предсказывается следующий элемент последовательности взаимодействий, поэтому прямое сопоставление результатов ЛР5 с ЛР1–ЛР4 ограничено. При этом удалось получить устойчивое обучение на датасете KION и рабочие метрики (HitRate@10 = 0,01615, MAP@10 = 0,00620, MRR@10 = 0,00243, NDCG@10 = 0,00423), тогда как в ориентировочных реализациях для той же постановки наблюдались проблемы со стабильностью обучения. На итоговое качество повлияли корректная обработка padding через mask_zero, фильтрация неизвестных объектов и выделение отдельной validation-выборки.

2. Сводные количественные результаты

В таблице ниже приведены все рассчитанные количественные показатели. Если для конкретной модели какая-либо метрика в ноутбуке не рассчитывалась, в таблице поставлен прочерк.

Лабораторная работа / модель	Постановка	HitRate@10	Precision@10	Recall@10	MAP@10	MRR@10	NDCG@10
ЛР1: Random	top-k рекомендация	—	0,00011	0,00032	0,00020	—	—
ЛР1: Popular	top-k рекомендация	—	0,01511	0,05984	0,05919	—	—
ЛР1: Top Popular	top-k рекомендация	—	0,01287	0,05172	0,01987	—	—
ЛР2: UserKNN	top-k рекомендация	0,12129	0,01288	0,04825	0,05061	—	—
ЛР2: ItemKNN	top-k рекомендация	0,02256	0,00237	0,00913	0,00798	—	—
ЛР3: ALS	top-k рекомендация	0,13653	0,01510	0,05386	0,05298	—	—
ЛР4: LightFM	top-k рекомендация	0,17590	0,01957	0,07214	0,07023	—	—
ЛР5: GRU4Rec	next-item prediction	0,01615	0,00161	0,01615	0,00620	0,00243	0,00423

Примечание. Для ЛР5 использовалась иная постановка задачи — предсказание следующего элемента последовательности; поэтому ее показатели, особенно MRR@10 и NDCG@10, следует интерпретировать отдельно от классического top-k сценария.

3. Итоговые выводы

- Наиболее сильный результат в сопоставимом top-k сценарии показала модель LightFM; следовательно, именно этот подход можно считать наиболее удачным итогом серии лабораторных работ для рассматриваемого датасета.
- Popular остается важным и практически полезным базлайном: метод прост в реализации, устойчив, интерпретируем и хорошо работает в сценарии холодного старта.
- ALS после подбора гиперпараметров показала конкурентоспособный результат и превзошла соседский подход ItemKNN, а также немного превысила UserKNN по MAP@10.
- Sequential-модель GRU4Rec решает более сложную задачу next-item prediction и потому должна интерпретироваться отдельно от классических top-k рекомендателей.

4. Заключение

Выполненные лабораторные работы позволили последовательно пройти путь от простейших эвристик до более сложных моделей факторизации, гибридных решений и последовательного моделирования. В результате были получены рабочие реализации нескольких классов рекомендательных алгоритмов и практическое понимание того, как выбор постановки задачи, подготовка данных и схема оценки влияют на итоговое качество рекомендаций.